大语言模型辅助工程设计中的执行反馈与审查——配电与供水网络的对照研究

谢宇宸　　任沛然 *
同济大学
* 通讯作者

摘要

大模型工程方案的评估不仅取决于是否获得反馈，还取决于声明动作是否被正确执行、修订是否破坏已有可行性。本文以 OpenTrust 为评估流程，在经可行参考筛选的 13 个配电与 3 个供水网络上，比较共享初始方案、开发测试和一次修订机会的反馈与审查路线。三种声明模型配置形成 96 个起点和 672 条相关路线。有候选执行反馈的同家族、跨家族路线分别合格 64/96、65/96，无反馈时为 46/96、44/96；保留八工况全部通过的数量分别由 51 增至 68、46 增至 70，收益主要来自配电。跨家族相对同家族仅有 5 个改善、4 个损失；完整审查输出与屏蔽审查均合格 64/96。旧供水方案的动作语义复评改变 6/24 条标签，局部回退进一步定位控制收益与设备修改退步。研究贡献是固定合同下的因素对照、执行映射核验与可追溯案例证据，支持本批候选反馈的效用，尚未建立额外审查或完整流程的普遍优势。

关键词： 工程人工智能；可执行合同；仿真反馈；动作语义；配对评估

1. 问题与研究定位

大模型可以为已有配电网或供水网提出设备加强位置与控制日程，但字段完整、求解成功和模型审查接受并不等于方案满足工程要求。评估中存在三个不同问题：候选方案是否遵守批准动作；宿主是否实际执行了这些动作；执行后的方案是否在固定运行条件下合格。若不分开这三层，反馈修订的收益可能被接口错误或动作映射偏差改变。

生成、反馈与修订已有先行基础。Self-Refine 研究模型自反馈 [6]，CRITIC 利用外部工具反馈修正输出 [3]，CriticBench 比较生成、批评及修正能力 [5]。工程领域已有大模型辅助供水建模与规划 [1, 2]、水网优化代理 [10]、电力优化验证内循环 [4] 和代码生成干预 [11]。因此，增加审查角色或把工具连接到模型本身不构成本研究的算法创新。

本文研究固定网络上的受约束设备与控制参数设计。我们提出三个可由实验回答的问题：共享初始方案时，候选执行反馈是否改善最终合格性；跨家族审查或完整审查输出是否带来额外收益；标签和修改收益是否确实对应所声明的工程动作。OpenTrust 在本文中是连接任务合同、执行验证与配对分析的评估流程，其价值由这些对照和核验体现，而不预设多角色结构必要或优于工程优化。主要证据包括 96 个共同起点的因素对照、开发与保留工况分离结果，以及执行语义复评和局部动作回退。

2. 固定合同与同起点对照

2.1. 任务、动作与合格判据

任务写为 $\mathcal{T} = (N, \mathcal{X}, S_{\text{dev}}, S_{\text{hold}}, \mathcal{C})$，分别表示源网络、批准参数空间、开发工况、保留工况和工程约束。方案 x 经宿主 $H(N, x, s)$ 映射为工况 s 的实际动作与测量，最终标签为

$$Q(x) = \mathbf{1}_{\mathcal{X}}(x) \prod_{s \in S_{\text{dev}} \cup S_{\text{hold}}} \prod_{j=1}^{J} \mathbf{1}[g_j(H(N, x, s)) \le 0] \,. \quad (1)$$

结构非法、求解不收敛或任一约束失败均记为不合格。每题有八个开发与八个保留工况；模型仅选择四个开发工况获取当前候选反馈，方案冻结后才评分全部十六个工况。$Q = 1$ 只表示有限合同内合格，不表示现场安全或完整连续运行包络已被覆盖。

源网络来自 SimBench、pandapower 和 WNTR 公开模型库 [7–9]。23 个候选网络中，16 个在有界搜索内取得可复算的可行参考，包括 13 个配电和 3 个供水网络；其余七项保留排除理由，未找到参考不等于不可行。设备加强上限依据参考需求校准，故这些任务代表筛选后的有限设计问题。六题在固定参考硬件下所有批准恒定档位均失败，而分时控制通过；九题记为设备与控制耦合设计，另保留一题易题锚点。这些标签不证明任意硬件都必须采用分时控制。

配电使用四个交流潮流快照，覆盖指定线路回路或变压器组中一个单元退出，不覆盖暂态稳定或完整 $N-1$ 安全性。供水保留原始水源水头、需求模式、储水初值与启停条件，不覆盖水质、瞬变或完整运维经济性。参考方案、精确保留组合及保留测量不提供给模型；源网络八个开发工况的基线行为对所有路线可见。

表 1. 两类合同的批准动作与合格判据。目录、阈值和运行条件在模型调用前固定；详细网络及工况见附录A、B。

领域	设计空间	全部工况须满足的约束
配电	负荷增长系数 1.30；所选线路加强为三回并联；变压器组采用统一并联单元数；共享四个六小时时段分接头日程。	母线电压 0.95–1.05 pu；线路及变压器负载率不超过 100%；指定单元退出时不失供且求解收敛。
供水	需求增长系数 1.25；批准管段管径加强；批准泵的四时段相对速度；指定水箱控制阈值偏移。	48 小时模拟，每 15 分钟检查：正需求节点压力 25–120 m、供水比例至少 99.9%、水箱位于原边界内、期末水位下降不超过 1 m。

2.2. 反馈与审查的权限

图1概括主流程。三种网关声明配置 `gpt-5.4`、`qwen3.8-max`、`kimi-k2.5` 在每网各重复两次，形成 $16 \times 3 \times 2 = 96$ 个初始方案 $x^{(0)}$。生产者先生成方案，再在未看到当前候选测量时选择四个不同开发工况；宿主执行这些测试，审查者给出判断、违反项、覆盖缺口和建议，原生产者修订一次。修订结构无效时保留初始方案；原方案非法时，沿用并不会修复其错误。

二乘二主对照只改变候选反馈可用性与审查者配置关系。无反馈路线屏蔽当前候选的证据，仍保留源网络基线；有反馈可能获得数值轨迹，也可能获得结构错误或求解失败信息。因此完整分母的效果不能全部解释为纯数值反馈作用。同家族审查使用生产者配置；跨家族在两次重复中依次使用另外两种配置。网关名称及请求设置不能认证真实后端权重，本文不将这种关系解释为架构因果效应。

审查屏蔽路线复用同家族有反馈路线的初始方案、选测与候选证据，将整个审查对象替换为屏蔽标记，再由原生产者修订。因此该对照检验完整审查输出的附加价值，同时移除判断、理由和建议，并非纯语言解释消融。每个起点共 11 次实际请求；四条主路线共享生产与选测调用。全部 1,056 次请求中两次失败，结果均保留；主对照不匹配 token、金额或内部推理计算。完整调用结构、设置和失败处理见附录C、F。

同起点 CPU 规则和有限搜索作为工程参照。规则按测量调整设备及控制，搜索依次评估八个候选、最多 32 条逻辑轨迹，只接受开发违反目标严格下降的候选。它们允许把非法初始方案重置为基础设计，预算和权限不同于模型路线，故不能据合格数作同资源算法排名；细节见附录C.1。另有每网一次的 CPU 从头设计，分母为 16。

3. 候选反馈有效，额外审查收益未建立

3.1. 完整分母与保留工况

图2汇总全部起点。初始方案合格 45/96；无反馈的同家族、跨家族路线分别为 46/96、44/96，有反馈时为 64/96、65/96。同家族反馈带来 20 个不合格转合格和 2 个反向变化，跨家族为 22 个与 1 个；配对净增量 $(G - L)/96$ 分别为 18.75、21.88 个百分点。

收益主要来自配电：同家族由 31/78 增至 48/78，跨家族由 27/78 增至 49/78。供水初始已合格 15/18，有反馈两条路线均为 16/18，无反馈跨家族却为 17/18，因此不能表述为两域一致受益。所有 96 个起点均保留，其中 18 个初始方案结构非法，主效果包含结构修复与物理约束改善。所有请求完成、初始可执行且四条数值轨迹完整的事后子集为 77 个起点；同家族由 44 增至 60，跨家族由 41 增至 60。该子集表明收益不只发生在非法起点上，但不替代完整分母，也未分离反馈各成分。

表 2. 不同工况组全部通过的方案数，各列分母均为 96。开发与保留各八个工况，完整合同为其交集。更细的所选／未选开发结果见附录13。

路线	开发	保留	完整合同
初始方案	46	48	45
无反馈／同家族	46	51	46
无反馈／跨家族	45	46	44
有反馈／同家族	65	68	64
有反馈／跨家族	66	70	65
审查屏蔽	66	69	64

冻结评分的事后分组结果见表2。保留八工况的同家族合格数由 51 增至 68（改善 20、损失 3），跨家族由 46 增至 70（改善 24、损失 0）。未选开发四工况也分别由 49 增至 70、48 增至 71。这表明本批反馈收益不限于模型选择的四个测试，但仍是同一组网络上的有限组合验证，而不是新网络泛化。

排除六个开发烟测起点后，分母为 90，完整合同同家族由 43 增至 60，跨家族由 41 增至 61。每次删除一个网络的六个起点，反馈净增量分别落在 13–18 和 16–22 个之间，因此不由某一个网络单独决定。这些是事后敏感性范围，不是置信区间。原入口曾在烟测后、保留评分和扩大调用前修订；排除烟测不能把研究恢复为未变更的预注册。详细分层与删样记录见附录F、E。

3.2. 额外审查与工程参照

有反馈跨家族相对同家族只有 5 个改善、4 个损失、87 个持平，净差 1.04 个百分点。完整同家族审查与屏蔽审查均合格 64/96，各有四个起点更好。总数相同不表示逐例等价；本研究既未建立稳定额外收益，也未以等效性或非劣效检验证明可以普遍删除审查。按有向配置细分时，审查方向与重复编号绑定，不能独立识别审查者身份的作用。

同起点 CPU 规则合格 63/96，有限搜索为 73/96；从头规则、搜索分别为 12/16、13/16。有限搜索的数量更高，但其额外候选和重置权限阻止了同资源优越性解

固定合同与起点	候选执行验证	审查与一次修订	冻结后统一评分
16 网、96 个初始方案；批准设备及控制动作。	选 4/8 开发工况；保存结构、求解及数值证据。	有／无候选反馈 × 同／跨家族审查；原生产者修订。	8 开发 + 8 保留工况；保留结果不回流模型。

图 1. 同起点评估流程，由左至右执行。主对照共享初始方案、选测和修订机会；反馈权限同时作用于审查与修订。另设完整审查屏蔽及 CPU 工程参照，路线并非独立样本。

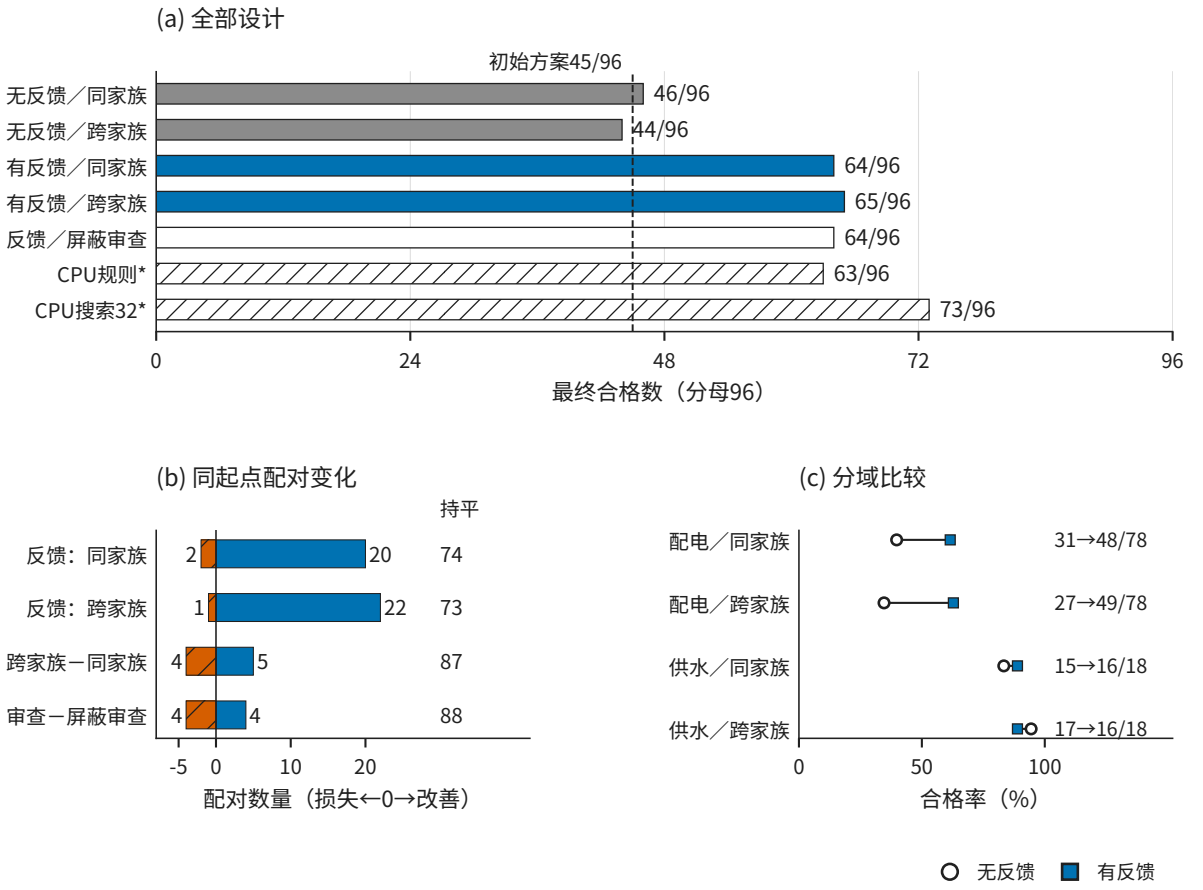


图 2. 完整合同结果与配对变化。各路线分母 96；初始合格数为 45。星号 CPU 参照的预算及结构重置权限不同。(b) 改善、损失与持平逐例计数。(c) 配电分母 78，供水 18；空心圆、实心方形分别表示无反馈、有反馈。

释。反过来，这些结果也没有证明复杂审查流程具有采用上的必要性。本文支持的是候选执行反馈在当前条件中的效用，而不是整个多角色流程相对简单工程程序的优势。

4. 执行语义与修改退步

4.1. 动作忠实性会改变标签

仿真宿主必须核查实际动作，而不能以求解器正常返回作为正确性证明。旧供水接口的原生开泵命令可能把预设速度恢复为 1；直接附加速度模式又可能重新打开原本关闭的泵。修正宿主把速度日程和原始启停条件联合编译，核查实际速度、可用窗口及阈值偏移。

对旧批次 24 条供水最终路线的零模型调用语义复评中，六条标签改变：四条由失败转通过、两条反向变化，全部发生于 ky4。该结果说明动作编译偏差足以改变工程评估，而不是只影响日志。旧模型没有收到修正测量，因此这次复评不能用于重新排列旧反馈路线的效能，也不能估计此类错误在其他宿主中的发生率；完整结果见附录D.1。

4.2. 局部回退区分有效修改与退步

在全部方案冻结后，依据改善、退步及开发通过但保留失败类别，按字典顺序选择可执行路线做事后回退。每

次仅恢复一个字段至初始值，其他最终参数与十六个工况不变。表3保留两个直接说明工程作用的案例；四例全量记录及测量见附录F的图4。

表 3. 局部动作回退的失败工况数，每个方案共 16 个工况。回退只支持指定硬件和其余字段固定时的作用。

案例／回退字段	初始	最终	回退后
低压乡村 2 ／分接头日程	16	0	16
中压城区／线路选择	0	5	0

低压乡村 2 的硬件保持不变，分接头日程由 $[-1,-2,1,-2]$ 改为 $[0,0,1,0]$ 后全部通过；恢复原日程使十六个工况再次失败。初始正常日第二、四个快照最高电压约为 1.0619、1.0642 pu，超过 1.05 pu 上限。中压城区则从全部通过退步为五个工况失败，恢复初始线路选择后重新全部通过。这两例分别定位了控制收益与设备修改退步，而不只是展示最终参数差异。

另外，Net1 的失败数从 3 降至 0；恢复泵速仍通过，恢复水箱阈值才重新失败，不能把收益全部归因于泵速。中压乡村最终仍有两个失败，恢复线路无效，恢复分接头后全部通过。这些回退提供指定字段的局部作用证据，不反映模型内部推理，也不证明总体机制或审查解释必要性。它们提示评估应分别保留声明参数、实际动作、测量与标签，以便发现不忠实执行和修改退步。

5. 材料与最小复用示例

5.1. 三种可复用对象

材料按用途提供三个层次。第一，冻结任务合同规定批准资产、动作目录、工况和判据，可用于审查一个候选方案是否回答了同一道工程题。第二，`analysis/compact_scores.json` 和 `analysis/analyze_scores.py` 保存逐路线评分与可重跑统计，使读者无需模型调用或物理仿真即可核对分母、配对、条件子集与敏感性结果。第三，最小 CPU 示例包含两域的源网络、合同、冻结初始与最终方案以及原评分实现，允许从网络重新计算结果，而不只读取已有标签。

完整原批次请求日志及实验环境仍保留在研究归档。轻量协议补件本身不是全量实验发行包；新增示例兑现的是两个指定网络的执行与方案评分入口，不是原 96 个起点的模型生成和审查重跑，也未自动接入新的模型服务。

5.2. 从源网络重放四份冻结方案

示例位于研究仓库的 `examples/engineering-replay/`，选择 `kerber_overhead` 与 `Net1`。两者均取原批次 `gpt-5.4`、重复 0、同家族有反馈路线的初始及最终方案，共四份方案，每份执行八个开发与八个保留工况。这里的 64 是工况评估次数，而不是 64 个新工程任务；配电每工况含四个潮流快照，供水每工况为 48 小时水力模拟。

在已具备记录依赖的环境中，进入示例目录运行 `pythonrun_demo.py` 即可开始重放，不需要 API 凭据、模型服务、GPU 或原研究目录。程序先核对源网络、合同和原评分实现的散列，再执行评分。表4给出对应的预期结果；供水初始方案不合格是应被重现的结果，不是复现失败。配电初始与最终参数相同，因此该案例检验保留方案的重放，不作为新增改进案例。

表 4. 最小示例的既有方案 CPU 重放。每份方案 16 个工况；标签与逐项判据均匹配冻结记录，未新增模型请求。

网络	初始 Q	最终 Q
Kerber 架空	1	1
Net1	0	1

首次运行的四份评分均匹配冻结记录；将示例打包后解压到另一目录、用同一解释器再次运行，64 个工况仍匹配，两次实际评分对象也逐值相等。另新建不继承系统包的虚拟环境，按记录依赖安装并检查无破损后，64 个工况再次匹配，实际评分与首次重放逐值相同。比较要求结构错误、求解失败、判据和标签精确一致，数值测量采用绝对 10^{-6}、相对 10^{-8} 的重放容差。这是结果比较容差，不改变电压、压力等工程合格阈值。运行记录、完整依赖版本清单和验证报告随示例提供。

5.3. 评估另一份方案，而非重新定义合同

示例也提供自定义方案入口：将符合任务结构的方案保存为 `candidate.json`，对 `run_demo.py` 指定 `--caseNet1`、`--designcandidate.json` 和输出路径，即可在同一冻结合同下运行十六个工况。该路径已执行验证；它输出候选的逐项测量、约束检查和最终标签，不要求新方案复现旧方案的数值。这样，人工或外部模型提交的参数可以进入相同判定器，而不必改写仿真逻辑。此入口的通过只表明调用和评分路径可用，不构成新模型性能实验。

两个默认案例已通过原环境、异目录解压和新隔离依赖环境重放；后者仍使用同一 Windows 机器与基础 Python。异机、跨操作系统兼容性及独立物理求解器尚未验证。新增网络还需重新确定资产权限、工况、物理约束、动作映射与可行参考；不能把替换输入文件等同于得到一个已验证的新任务。公开保留工况用于核查，后续模型实验仍需隔离其提示输入，并重新冻结生成与审查协议。

研究源码与材料入口为 https://github.com/Sumimi24/opentrust-research，说明页面为 https://sumimi24.github.io/opentrust-research/。当前复用价值因而可以具体表述为：检查同一合同、重算已有统计、重放两域方案，以及评分符合既有合同的另一份参数设计；更广网络的效用和整个流程的外部复现仍待验证。

6. 讨论与结论

现有结果支持三个层次的结论。第一，在筛选后的有限合同中，候选执行反馈改善了完整合同及保留工况的合格数，且主要来自配电。第二，更换审查配置或提供完整审查输出的稳定附加收益尚未建立，不能用系统角色数量替代效用验证。第三，动作语义和局部退步可以改变标签，必须与方案质量共同审计。这些结论属于工程评估的实证增量，不构成新的生成算法或普遍方法优势。

适用范围受到可行参考筛选、公开网络相关性及供水样本偏少的限制。96 个起点与 672 条路线不能当作独立网络样本；声明模型身份未认证，token、费用与内部计算未匹配。审查数值引用尚未可靠逐项核验，故不报告解释失实率。同软件同判据的冻结方案复算只验证重现性，不能替代独立物理模型或现场测量；局部回退也只是事后选例。

后续工作应对准尚未回答的决定：在同一初始方案上分离结构诊断、数值反馈与审查建议，检验何时需要审查；在独立来源网络和困难供水任务上预先冻结协议，检验收益迁移；用预算与权限匹配的工程优化对照评估采用成本。当前可以复用的是明确的合同、失败处理和评分证据。它们使后续方案能够在相同条件下被检查，但未来可扩展性本身不计作已完成的性能贡献。

参考文献

[1] N. Do, A. Marchi, and P. Hayde. Accelerating water distribution systems planning and design with generative artificial intelligence models. *Cambridge Prisms: Water*, 4:e2, 1–7, 2026. 1

[2] Yinon Goldshtein, Gal Perelman, Assaf Schuster, and Avi Ostfeld. Large language models for water distribution systems modeling and decision-making. *arXiv preprint arXiv:2503.16191v2*, 2026. 1

[3] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan, and Weizhu Chen. CRITIC: Large language models can self-correct with tool-interactive critiquing. In *International Conference on Learning Representations*, 2024. 1

[4] Yunkai Hu, Tianqiao Zhao, and Meng Yue. From natural language to solver-ready power system optimization: An LLM-assisted, validation-in-the-loop framework. *arXiv preprint arXiv:2508.08147*, 2025. 1

[5] Zicheng Lin, Zhibin Gou, Tian Liang, Ruilin Luo, Haowei Liu, and Yujiu Yang. CriticBench: Benchmarking LLMs for critique-correct reasoning. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 1552–1587, 2024. 1

[6] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-Refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, 2023. 1

[7] pandapower. Power system test cases and network documentation. `https://pandapower.readthedocs.io/en/latest/networks.html`. Accessed 2026-10-15. 1, 6

[8] SimBench. Benchmark network documentation. `https://simbench.readthedocs.io/en/stable/networks.html`. Accessed 2026-10-15.

[9] U.S. Environmental Protection Agency. WNTR network library documentation. `https://usepa.github.io/WNTR/libraries.html`. Accessed 2026-10-15. 1, 6

[10] Jiaqi Wen, Pingbo Tang, Shaolei Ren, and Jianyi Yang. WaterAdmin: Orchestrating community water distribution optimization via AI agents. *arXiv preprint arXiv:2604.10343*, 2026. 1

[11] H. Wu, X. Wang, and Z. Fan. Knowledge boundary probing and demand-guided intervention for LLM-based power system code generation. *arXiv preprint arXiv:2605.31478v2*, 2026. 1

A. 网络合同与原始证据范围

本附录记录已完成批次的实际实现。补件中的协议冻结时间为 2026 年 10 月 14 日 12:18:12 UTC；研究包含正文已披露的烟测入口修订。表5列出全部入选任务，而非将同一网络上的重复推理视为不同工程题。表内 S、P、W 分别表示 SimBench、pandapower 网络库和 WNTR 模型库 [7–9]；C、T、E 分别为耦合设计、参考硬件下的时序条件难度和易题锚点。

表中 $a{:}b$ 表示含端点的全部整数档位，$\mathcal{V} = \{0.95, 1, 1.05, 1.10\}$ 为相对泵速目录。配电加强使所选线路拥有三回相同并联回路，四时段分接头的日循环绝对变化和不超过 18；供水加强将所选管径乘以 1.5。三项供水任务各有一个可偏移阈值的水箱，目录均为 $\{-0.5, 0, 0.5, 1, 1.5\}$ m；其余水箱不新增决策。设备上限在参考搜索后设为参考所需加强数加一，并截断到批准资产总数，因此是经过可行参考校准的合同。

SimBench 任务对应 `1-LV-<name>--0-no_sw` 与 `1-MV-<name>--0-no_sw`，名称分别为 `rural1--3`、`semiurb4--5`、`urban6` 和 `rural/semiurb/urban/comm`。CIGRE 使用 `create_cigre_network_mv`；Kerber 使用 `create_kerber_landnetz_freileitung_1` 与 `create_kerber_landnetz_kabel_1`。供水原件来自 WNTR 模型库。逐网络 ID、源地址、原始文件散列、批准资产 ID、泵与水箱 ID 均保存在任务 JSON 和 `data/网络合同明细.csv`。

23 个候选源网络中的七项排除为：`cigre_hv`、`cigre_lv`、`ky10`、`Net2`、`Anytown`、`BWSN1` 在已实施的有界参考搜索内未找到可行设计；`Net6` 的资格检查报告在 11:15:00 不收敛。上述排除均保存在`qualification_gate.json`，不构成全局不可行性证明。Anytown 和 BWSN1 的网络清单记录了固定 Git 提交来源，但它们不进入本研究结果分母。

B. 开发与保留工况的确定性划分

每题有八个开发与八个保留工况，构成确定性运行组合，而非随机训练／测试拆分。生产者只选择四个不同开发工况获取当前候选反馈；最终评分使用全部十六个工况。模型可见运行包络及原网络八个开发工况的基线行为，不能看到精确保留组合、参考答案或保留输出。以下未列出的乘子均为 1，空间幅度为 0，且无退出事件。

配电四个时段为 00–06、06–12、12–18、18–24 时，基础负荷／可再生系数依次为 $(.7, .15)$、$(1.4, .1)$、$(.45, 2.5)$、$(1.2, 0)$；负荷另乘 1.30。线路 a, b 为按四个基础快照最大负载排序后的前两条批准资产。开发退出指定第一个变压器组，保留退出指定最后一个组；单组网络两者相同。时段 i 使用 NumPy `default_rng(z+i)`，为负荷和 `sgen` 分别抽取 $U(1-s, 1+s)$ 乘子；常规 `gen` 不随可再生系数缩放。

供水需求另乘 1.25；同一节点的全部需求序列使用同一 $U(1-s, 1+s)$ 空间因子，随机发生器为 `default_rng(z)`。应急节点取正基础需求最大的节点，流量为 $\min(0.025, \max(0.002, 0.03 \sum_j d_j))$ m³/s，其中 d_j 为乘固定增长系数 1.25 后、尚未乘工况及空间因子的正基础需求。四个六小时泵速时段在 48 小时内重复；水力及报告步长为 900 s，含首尾共 193 个检查时刻。完整工况 ID、退出资产 ID 和各网络取水流量以任务 JSON 为准。

C. 模型角色、请求参数与 CPU 对照

主路线的四个逻辑模型阶段为生产初始方案、选择测试、审查、修订。同一生产者负责生成初始方案、选测和最终修订；只有审查者按因素条件改变。表8中的 G、Q、K 分别代表网关声明的 `gpt-5.4`、`qwen3.8-max`、`kimi-k2.5`。重复编号为 0、1；每个网络覆盖六个有向跨模型配对。

1,056 条实际请求均未显式提供温度或生成随机种子，有效默认温度未知，重新调用也不保证输出相同。主路线在每个起点内按 `Random(2026101404+job_index)` 打乱执行顺序；该种子只控制路线顺序。每次声明调用只有一次物理尝试，不自动重试。模型声明名、返回名与这些参数不能认证后端权重。

有反馈条件提供相同开发测试产生的完整候选证据对象，包含结构错误、求解错误、判据与数值测量，并非仅有数值。无反馈条件屏蔽该候选对象，但仍可见源网络基线。直接反馈分支将整个 `reviewer_feedback` 对象替换为屏蔽状态，因而同时移除审查结论、违反项、覆盖缺口和建议；它不是只删除一个语言解释字段。该分支复用初始方案、选测和候选证据，另作一次修订，只有三个有效信息阶段，不能据此声称等 token 或等金额。修订结构无效时保留初始方案；初始方案原本无效时也不会自动恢复为合法设计。

C.1. 领域规则及八候选贪心邻域

同起点 CPU 对照使用模型初始方案及同四个开发测试，因而依赖前两个 API 阶段。初始方案结构无效时，它们允许重置为基础设计；这与主路线的处理权限不同。配电规则加强退出线路或过载最严重线路，遇变压器退出或过载则取最大并联数，再按逐时段最坏电压与原设备分接头步长调整档位，并投影回批准目录；若所得结构无效，则恢复原档位。供水规则按逐时段超压优先降一档、欠压升一档；出现欠压时按批准顺序增加一个管段加强，期末储量不足时把可调水箱阈值升一档。

有限搜索固定记录八次候选尝试：第 0 次为初始方案或重置设计，第 1 次为规则候选，第 2–5 次依次上调时段 0–3 的一个相邻档位，第 6–7 次依次下调时段 0–1。每次都从当前最优设计出发。配电第 7 次另尝试增加首个未选批准线路；仅有零档位的网络在后续尝试中也增加线路。供水每次共同改变所有决策泵在指定时段的相邻速度。边界截断或规则无变化可能产生重复候选。

每候选测同四个开发工况，以约束违反目标严格下降超过 10^{-9} 为接受条件。结构错误罚 10000，引擎错误工况罚 1000；其余失败工况累加失败判据数，再加电压越界量乘 10 与过载量除 100，或压力越界量分别除

表 5. 16 个入选网络的冻结合同。配电规模为母线／线路／变压器组数；供水规模为节点／管道／水箱／泵数，其中节点仅计 junction。设备栏为允许加强数量上限／批准资产数；配电均允许每组 1、2 或 3 台相同变压器。

网络	来源	规模	设备	控制目录	难度
低压乡村 1	S	15/13/1	3/13	−2:2	C
低压乡村 2	S	97/95/1	7/95	−2:2	T
低压乡村 3	S	129/127/1	3/127	−2:2	T
低压城郊 4	S	44/42/1	7/42	−2:2	C
低压城郊 5	S	111/109/1	9/109	−2:2	T
低压城区 6	S	59/57/1	7/57	−2:2	C
中压乡村	S	95/99/2	13/99	−9:9	T
中压城郊	S	115/121/2	17/121	−9:9	T
中压城区	S	136/147/2	25/147	−9:9	C
中压商业	S	103/109/2	25/109	−9:9	T
CIGRE 中压	P	15/15/2	9/15	0	C
Kerber 架空	P	15/13/1	9/13	0	C
Kerber 电缆	P	18/16/1	3/16	0	C
ky4	W	959/1156/4/2	1/16	$\mathcal{V}$，2 台决策泵	E
Net1	W	9/12/1/1	12/12	$\mathcal{V}$，1 台决策泵	C
Net3	W	92/117/3/2	13/16	$\mathcal{V}$，2 台决策泵	C

表 6. 配电八个开发与八个保留工况。L, G, s, z 分别为负荷乘子、可再生出力乘子、空间幅度和种子；T_I, A_I, B_I 分别表示指定变压器组、线路 a 或 b 在时段集合 I 退出一个单元。

开发工况	参数	保留工况	参数
正常日	默认	正常	$L = 1.02, G = .96, s = .06, z = 8601$
高负荷日	$L = 1.04$	高负荷	$L = 1.06, G = .90, s = .08, z = 8602$
高可再生日	$L = .95, G = 1.05$	高可再生	$L = .93, G = 1.07, s = .06, z = 8603$
空间扰动日	$s = .08, z = 1601$	变压器退出	$T_{\{0,1,3\}}, L = 1.025, s = .08, z = 8604$
变压器退出	$T_{\{1,3\}}$	线路退出	$A_{\{0,1,2\}}, s = .09, z = 8605$
线路退出	$A_{\{1,2\}}$	复合退出	$B_{\{1,3\}}, T_{\{1,3\}}, L = 1.01, s = .08, z = 8606$
复合退出	$B_{\{1\}}, T_{\{1\}}, s = .06, z = 1602$	低负荷	$L = .92, G = 1.02, s = .08, z = 8607$
轻载日	$L = .90, G = 1.04$	混合	$L = 1.03, G = 1.03, s = .10, z = 8608$

25 ／ 120、供水缺口乘 10 与超额期末水位下降。通过方案目标为零，不再按能耗、资本或金额比较；相同目标不替换。八候选乘四工况即 32 条逻辑轨迹上限，复用的初始方案测量不重复物理执行。

纯 CPU 从头设计另以每网一次计数，不依赖模型初始方案。它预装批准列表前若干项直至加强上限，配电取最大变压器并联数；配电固定选择正常、高负荷、高可再生、复合退出，供水选择高需求、低需求、老化高需求、老化应急。随后使用同一规则及有限搜索，选择时不查询保留工况。

D. 资格检查、软件环境与语义复评

拓扑检查先比较同域网络节点数与边数，再调用 `networkx.is_isomorphic`。配电图由 `create_nxgraph(...,respect_switches=True)` 构造，供水图由 `to_graph().to_undirected()` 构造，均未指定属性匹配器。16 个组仅表示该图表示下未发现结构同构，不证明物理或统计独立。八个首次进入本项目的网络为四个 SimBench 中压网络、CIGRE 中压、两个 Kerber 网络及 Net1；公开网络的训练污染未排除。

时序资格检查保持参考硬件固定：低压乡村 2、低压乡村 3、低压城郊 5 各检查全部五个恒定档位，中压乡村、城郊、商业各检查全部十九个恒定档位，均不通过，而对应参考分时方案通过。其余九题记为耦合设计，ky4 为基础设计已通过的易题。难度标签不证明任意硬件都必须使用分时控制，也不是与人类难度或模型能力校准后的难度尺度。

配电调用 `runpp`,设 `numba=False`、`tolerance_mva=1e-9`、最大迭代 50；未供电母线或不收敛均失败。电压容差为 10^{-6} pu，负载率容差为 10^{-4} 个百分点。供水合同指定 EPANET 2.2, 通过 WNTR 的 `EpanetSimulator` 执行，并设置 `convergence_error=True`；压力相关需求模型最低压力为 0、所需压力为 25 m。压力及水位容差为 0.01 m，供水比例无附加容差。冻结环境表未单

表 7. 供水八个开发与八个保留工况。D, R, s, z 分别为需求乘子、粗糙度乘子、空间幅度和种子；$F_{u:v}$ 表示第 u 至 v 小时的应急取水。

开发工况	参数	保留工况	参数
正常日	默认	正常	$D = 1.02, s = .04, z = 8701$
高需求日	$D = 1.08$	高需求	$D = 1.09, s = .05, z = 8702$
低需求日	$D = .78$	低需求	$D = .79, s = .05, z = 8703$
应急日	$F_{8:12}$	应急	$D = 1.02, F_{17:21}$
老化高需求	$D = 1.06, R = .94$	老化高需求	$D = 1.07, R = .92, s = .04, z = 8704$
空间高需求	$D = 1.04, s = .06, z = 1701$	老化低需求	$D = .80, R = .92, s = .05, z = 8705$
老化应急	$R = .94, F_{30:34}$	老化应急	$D = 1.015, R = .92, F_{21:25}$
空间低需求	$D = .80, s = .06, z = 1702$	空间扰动	$D = 1.035, s = .08, z = 8706$

表 8. 模型角色与固定请求设置。三种配置各有 352 次实际请求；所有阶段均使用各配置的同一组设置。

生产／修订	同家族审查	跨家族 0/1	输出上限	推理设置
G	G	Q/K	`max_completion_tokens=16384`	`reasoning_effort=low`；流式输出
Q	Q	K/G	`max_tokens=32768`	`enable_thinking=true`; `reasoning_effort=medium`
K	K	G/Q	`max_tokens=32768`	`thinking.type=enabled`

表 9. 冻结环境记录和实际求解设置。版本表为原记录，未用当前系统版本替换。

组件	版本／设置
Python	3.12.14，64 位 MSC
pandapower	3.5.6
WNTR	1.5.0
SimBench	1.6.3
NumPy	2.4.6
SciPy	1.18.1
Matplotlib	3.11.2
线程环境	OMP、OpenBLAS 各 2

独记录 NetworkX 版本、CPU 型号及 EPANET 二进制散列；同软件同判据复算不替代独立物理模型或现场测量验证。

D.1. 旧供水路线的执行语义敏感性

旧批次包含 Net3、ky4 两网，`gpt-5.4`、`deepseek-v4-pro` 两种生产者及两次重复，共八个起点。原生开泵命令可把预设速度恢复为 1；零 API 复评把原有使能条件编译为原方案声明的恒定相对速度，并保留其余源控制和旧判据。表10中的六个标签变化全部发生于 ky4，合计四个失败转通过、两个通过转失败；初始方案另从 6/8 合格变为 5/8。

D.2. 补件内容与复现边界

轻量补件`evidence/protocol/` 保存冻结协议、16 题合同与参考及资格检查、软件记录、旧语义复评和相关

表 10. 旧 24 条最终路线的零 API 语义复评。原语义与声明恒速列为合格数；末两列为失败转合格及反向数量。旧模型没有接收新语义测量，不能据此重新比较旧反馈路线的效能。

旧路线	原语义	恒速	失转合	合转失
跨模型审查	6/8	5/8	0	1
无工具修订	5/8	8/8	3	0
同模型审查	7/8	7/8	1	1
合计	18/24	20/24	4	2

脚本。`manifest.json` 记录文件来源与散列；请求设置统计是派生记录，声明依据见`evidence/appendix_evidence_map.json`。补件未含源网络输入、全量模型请求或完整运行时，重新仿真仍需获取对应输入与依赖；它不是可独立重跑全部实验的软件发行包。

E. 新增冻结评分分析的配对范围

本节、正文的工况分离结果及附录F的配置分层、删样明细均为事后分析，仅读取既有冻结评分；未新增模型请求或仿真。紧凑记录保留初始及最终方案、工况标签、标量测量和判据，省略请求文本与详细时间轨迹。`analysis/analyze_scores.py` 可从`analysis/compact_scores.json` 重算汇总。原评分提取和紧凑记录重跑的汇总逐值相同；该检查验证记录与统计一致性，不重新验证物理宿主。

六个有向生产者／审查者配对各含 16 个起点。表11比较每个子集内部的配对路线，而非在同一初始方案上对两个不同审查者做完全交叉。某生产者的审查配置由重复编号决定；比较该生产者的两种审查方向

时，同时改变了初始方案的重复编号。因此这些子集不能独立识别审查者身份的因果效应。G、Q、K 的声明配置见附录C。

表 11. 有向配对的完整合同结果，每行分母 16。无／有反馈计数均为跨家族路线。末两列为改善／损失：反馈列比较同方向的无与有反馈；跨同列比较有反馈的跨家族与同家族。合计分别为 22/1 与 5/4。

生产／审查	无反馈	有反馈	反馈	跨同
G → Q	8	12	4/0	0/0
G → K	8	11	4/1	0/2
Q → G	11	14	3/0	2/0
Q → K	9	12	3/0	1/1
K → G	3	8	5/0	2/0
K → Q	5	8	3/0	0/1

工况组端点均要求合法结构及组内所有测试通过。脚本检查 672 条路线键唯一、每个起点含七条路线、初始设计与选测共享、每题八开发与八保留工况互斥，并从逐工况标签重建完整合同、开发及保留端点，与存储标签一致。结构非法和缺失测试按失败保留分母。烟测键由`protocol.smoke_jobs` 与烟测审计中 42 条路线的六个唯一键交叉确认；删网络时同时删除该网络三种生产者的两次重复。全部逐起点标签、配对、生产者分层、六向配对和删网络结果以`analysis/` 中的 CSV 与`final_summary.json` 为准。未将 672 条相关路线当作独立样本进行显著性推断。

F. 逐网络、失败输出与局部动作的补充结果

F.1. 结构合法性与无效修订

96 个初始工程方案中有 18 个存在结构错误，只有其余 78 个产生完整的四工况候选数值轨迹。表12列出模型路线的最终结构错误与无效修订后沿用初始方案的次数。两列不互斥，也不能相加：沿用初始方案可能保留一个合法设计，也可能保留已有错误。主合格数以全部 96 个起点为分母，因而反馈效应同时包含结构合法性改善与物理约束满足的变化。

表 12. 模型路线的结构错误和无效修订处理。各列分母均为 96；初始结构错误为 18。

路线	最终结构错误数	无效修订后沿用次数
无反馈／同家族	13	18
无反馈／跨家族	12	13
有反馈／同家族	4	7
有反馈／跨家族	2	3
审查屏蔽	3	4

F.2. 工程参照、审查判断与条件分析

同起点 CPU 规则合格 63/96，有限搜索合格 73/96。搜索比最佳主模型路线多八份合格方案，但拥有更多候选、仿真轨迹和结构重置权限，该差异不是同资源算法优越性证据。纯 CPU 从头规则与有限搜索分别合格 12/16、13/16；分母不同，不与模型路线的 96 混用。

相对初始工程方案，有反馈同家族使 20 个方案由不合格转为合格、1 个方案反向变化；有反馈跨家族使 20 个方案由不合格转为合格，未观察到反向变化。审查意见与实际合格性仍有差异：同家族有反馈审查接受 22 个初始工程方案，其中两个不满足完整合同；跨家族接受 21 个，本研究未观察到误接受。这是小分母观察，不构成错误率担保。无反馈跨家族没有接受意见，不能将零分母记为零风险。

为检查结果是否仅来自结构修复，另作事后条件描述。所有请求完成、初始工程方案可执行且四条候选数值轨迹完整的子集包含 77 个起点；无反馈同家族、跨家族合格数分别为 44、41，有反馈两条路线均为 60，审查屏蔽为 61。该条件子集允许在相同数值测量条件下描述审查输出的差异，但它按初始工程方案和调用状态筛选，不能替代 96 的完整分母，也不能分离语言解释、审查判断及修改建议的效应。

F.3. 四个局部回退案例的完整记录

全部结果冻结后，依据改善、退步及开发通过但保留失败三个类别，按字典顺序选取可执行路线，进行事后局部回退。每次仅将指定字段恢复为初始工程方案值，其余最终参数及十六个评分工况固定。图4记录四个案例中的失败工况数量，并将动作变化与实际测量对照。选例属于局部机制分析，不是总体代表性抽样。

在低压乡村 2 的跨家族反馈案例中，硬件保持不变，分接头日程由 $[-1,-2,1,-2]$ 改为 $[0,0,1,0]$，失败工况数从 16 变为 0。恢复初始工程方案日程后，16 个工况再次失败。初始工程方案正常日第二、四个快照的最高电压约为 1.0619、1.0642 pu，超过 1.05 pu 上限。该干预支持指定硬件和固定工况下的日程作用，不证明语言解释必要或任意硬件均需要同一日程。

Net1 供水案例中，失败数从 3 变为 0；仅恢复泵速仍然通过，恢复水箱阈值偏移则重新出现 3 个失败。该案例不能把全部改善归因于泵速。中压城区案例初始工程方案全部通过，修订后有 5 个失败；恢复初始工程方案线路选择后全部通过，说明修改可能引入退步。中压乡村案例最终仍有 2 个失败；恢复线路选择仍有 2 个失败，恢复分接头则全部通过，显示当前控制变化与保留失败有关。

这类证据回答的是某一实际动作在固定其他字段后是否改变约束满足，不展示模型内部推理。与旧供水语义复评共同表明，必须分别保存声明参数、实际动作、测量、审查意见和最终标签；可信求解器不能弥补错误的动作编译。

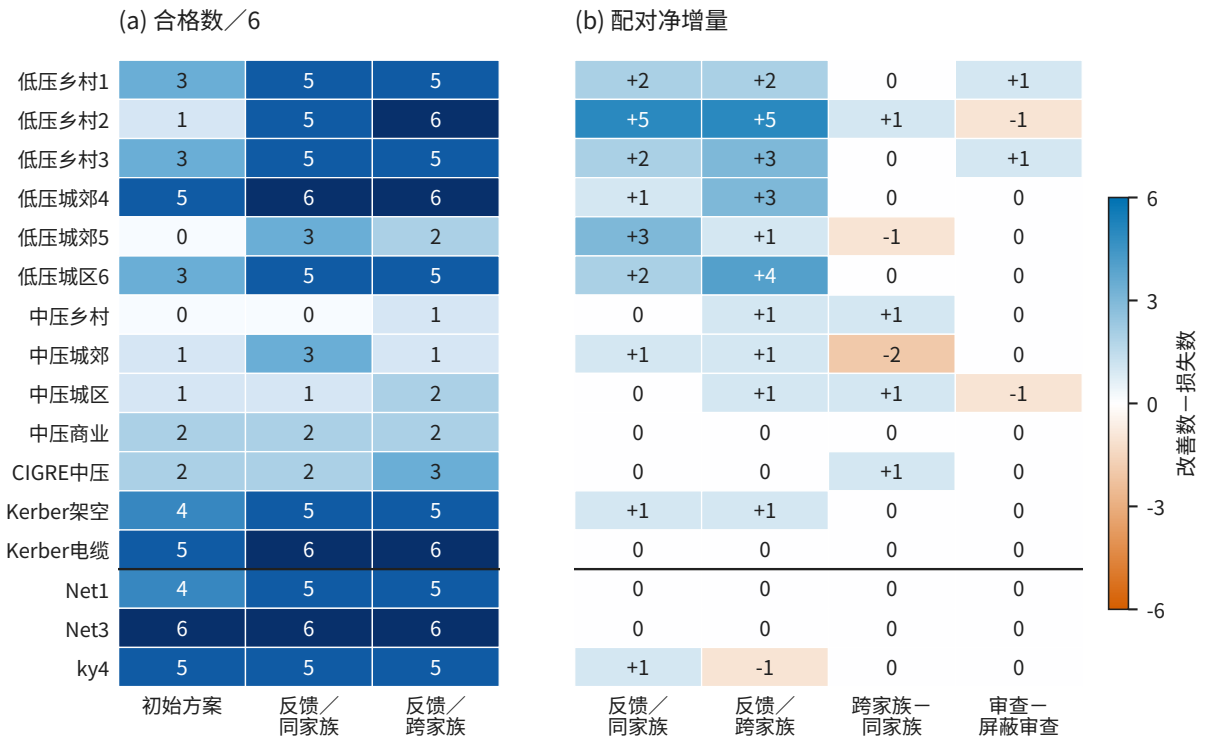


图 3. 源网络层面的合格数与配对净增量。每行包含三种声明配置各两次推理，共六份初始工程方案；横线以下为供水网络。(a) 初始工程方案与有反馈最终结果。(b) 各配对的改善数减损失数；零可能包含相互抵消。不同拓扑不等于统计独立，公开网络的训练污染未排除。

F.4. 入口修订、资源记录与复算

六个开发烟测起点完成 66 次正常请求，但原先要求全部主路线结构合法的入口未通过，24 条主路线中 22 条结构合法。随后在任何保留评分和扩大调用之前记录入口修订：不合法输出作为模型失败保留，继续要求传输、测试选择与工具执行可用，并要求每域至少存在一条开发可行路线。旧结果未删除，烟测候选保留在总批次中。因此本研究包含事后入口修订，不能称为完全未变更的预注册。

七条路线共形成 $96 \times 7 = 672$ 个最终评分结果；它们共享起点和网络，不能当作 672 道独立题。主因素对照匹配起点、选测与修订机会，未匹配 token、金额或内部推理计算。实验应用程序接口（API）记录 1,056 次实际请求，其中 1,054 次完成、一次 HTTP 错误、一次传输错误；使用量记录合计 24,135,950 个词元（token），两次请求缺少使用量，不按零成本处理。94 个起点所有调用阶段完成。冻结后全部 96 份初始工程方案和 672 条最终路线的开发与保留判据均已重新执行并一致；这属于同软件同判据的重现性核验。

F.5. 开发与保留工况的分离结果

为区分对反馈测试的适配与保留工况表现，按现有冻结评分进行事后描述分析。表13的每个端点均要求结构合法且该组全部工况通过；缺失或求解失败不计为通过，全部 96 个起点均保留。所选与未选开发组各含四个工况，保留组含八个工况。

保留八工况的配对改善／损失为同家族 20/3、跨家族 24/0。开发与保留各八工况同时改善的起点分别为 19、22 个；同家族另有两个同时退步、一个仅保留退步。因此收益不限于所选反馈工况，但不保证逐例改善，亦不是新网络泛化验证。

F.6. 配置分层与样本敏感性

表14按声明配置分层；能力、初始方案和推理设置同时变化，层间差异不是架构因果效应。六个有向配对见附录E。

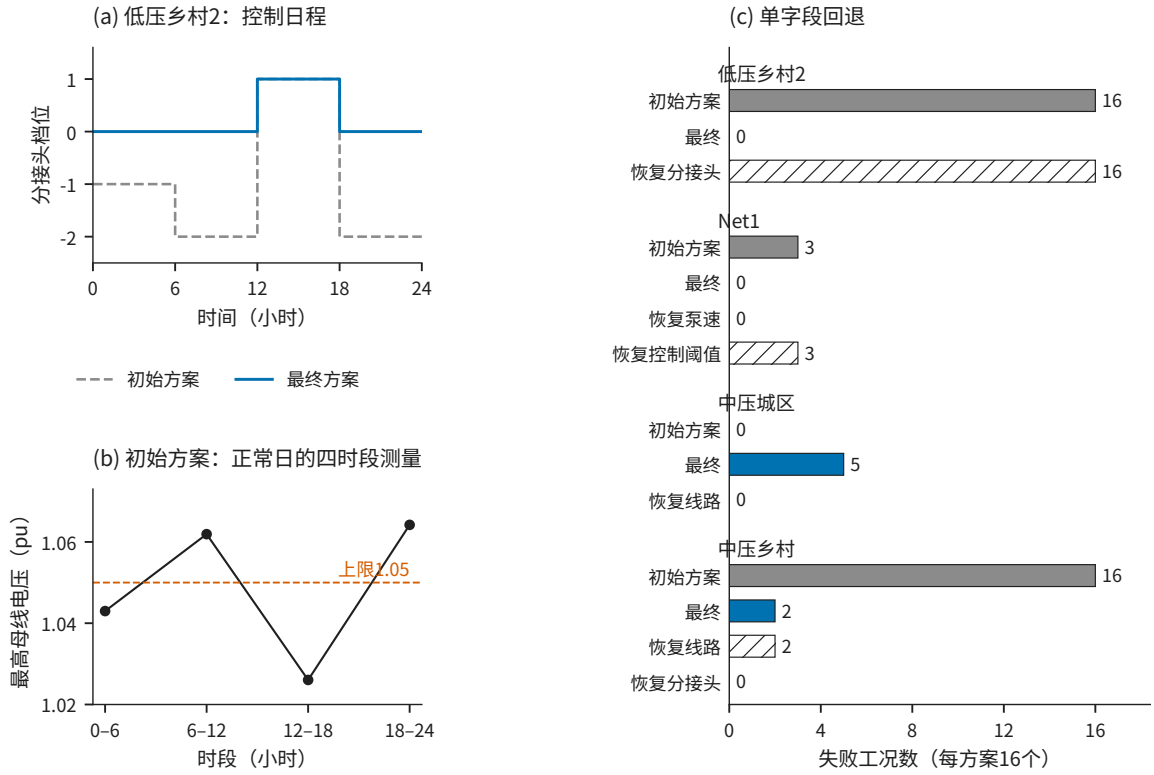


图 4. 局部动作干预及物理测量。(a,b) 低压乡村 2 案例的分接头日程和初始工程方案正常日四个潮流快照；时段标记不代表连续时间轨迹。(c) 四个事后案例在十六个评分工况中的失败数量；每次仅回退指定字段，零表示全部通过。局部回退不证明总体发生率、审查解释必要性或独立物理模型有效性。

表 13. 冻结方案在不同工况组中的合格数。所有单元格分母均为 96；列标题括号内为每组工况数，不是样本量。*CPU 参照的预算及权限不同。

路线	所选开发 (4)	未选开发 (4)	开发 (8)	保留 (8)	完整合同 (16)
初始方案	49	49	46	48	45
无反馈／同家族	48	49	46	51	46
无反馈／跨家族	46	48	45	46	44
有反馈／同家族	70	70	65	68	64
有反馈／跨家族	70	71	66	70	65
审查屏蔽	69	69	66	69	64
CPU 规则 *	67	67	65	67	63
CPU 有限搜索 *	81	78	77	75	73

表 14. 按生产者分层的完整合同结果，各层分母 32。每格为无反馈 → 有反馈的合格数，括号内为配对改善／损失。

生产者	同家族审查	跨家族审查
`gpt-5.4`	17 → 25 (8/0)	16 → 23 (8/1)
`qwen3.8-max`	20 → 24 (6/2)	20 → 26 (6/0)
`kimi-k2.5`	9 → 15 (6/0)	8 → 16 (8/0)

排除六个开发烟测起点后，各路线分母为 90：完整合同同家族 43 → 60（改善 19、损失 2），跨家族 41 → 61（21/1）；保留八工况分别为 48 → 64、43 → 66。该事后排除不能恢复未变更的预注册。

每次删除一个网络的六个起点（余下分母 90），完整合同净增量为同家族 13–18、跨家族 16–22 个（14.44–20.00、17.78–24.44 个百分点）；保留八工况为 12–17、19–24 个。正向增量不由单一网络决定；该敏感性范围不是置信区间，不消除来源相关性或供水样本偏少的限制。