大语言模型辅助工程设计中的执行反馈与审查——配电与供水网络的对照研究

谢宇宸　　任沛然 *
同济大学
* 通讯作者

摘要

大模型工程方案的评估不仅取决于是否获得反馈，还取决于声明动作是否被正确执行、修订是否破坏已有可行性。本文以 OpenTrust 为评估流程，在经可行参考筛选的 13 个配电与 3 个供水网络上，比较共享初始方案、开发测试和一次修订机会的反馈与审查路线。三种声明模型配置形成 96 个起点和 672 条相关路线。有候选执行反馈的同家族、跨家族路线分别合格 64/96、65/96，无反馈时为 46/96、44/96；保留八工况全部通过的数量分别由 51 增至 68、46 增至 70，收益主要来自配电。跨家族相对同家族仅有 5 个改善、4 个损失；完整审查输出与屏蔽审查均合格 64/96。旧供水方案的动作语义复评改变 6/24 条标签，局部回退进一步定位控制收益与设备修改退步。研究贡献是固定合同下的因素对照、执行映射核验与可追溯案例证据，支持本批候选反馈的效用，尚未建立额外审查或完整流程的普遍优势。

关键词： 工程人工智能；可执行合同；仿真反馈；动作语义；配对评估

1. 问题与研究定位

大模型可以为已有配电网或供水网提出设备加强位置与控制日程，但字段完整、求解成功和模型审查接受并不等于方案满足工程要求。评估中存在三个不同问题：候选方案是否遵守批准动作；宿主是否实际执行了这些动作；执行后的方案是否在固定运行条件下合格。若不分开这三层，反馈修订的收益可能被接口错误或动作映射偏差改变。

生成、反馈与修订已有先行基础。Self-Refine 研究模型自反馈 [6]，CRITIC 利用外部工具反馈修正输出 [3]，CriticBench 比较生成、批评及修正能力 [5]。工程领域已有大模型辅助供水建模与规划 [1, 2]、水网优化代理 [10]、电力优化验证内循环 [4] 和代码生成干预 [11]。因此，增加审查角色或把工具连接到模型本身不构成本研究的算法创新。

本文研究固定网络上的受约束设备与控制参数设计。我们提出三个可由实验回答的问题：共享初始方案时，候选执行反馈是否改善最终合格性；跨家族审查或完整审查输出是否带来额外收益；标签和修改收益是否确实对应所声明的工程动作。OpenTrust 在本文中是连接任务合同、执行验证与配对分析的评估流程，其价值由这些对照和核验体现，而不预设多角色结构必要或优于工程优化。主要证据包括 96 个共同起点的因素对照、开发与保留工况分离结果，以及执行语义复评和局部动作回退。

2. 固定合同与同起点对照

2.1. 任务、动作与合格判据

任务写为 $\mathcal{T} = (N, \mathcal{X}, S_{\text{dev}}, S_{\text{hold}}, \mathcal{C})$，分别表示源网络、批准参数空间、开发工况、保留工况和工程约束。方案 x 经宿主 $H(N, x, s)$ 映射为工况 s 的实际动作与测量，最终标签为

$$Q(x) = \mathbf{1}_{\mathcal{X}}(x) \prod_{s \in S_{\text{dev}} \cup S_{\text{hold}}} \prod_{j=1}^{J} \mathbf{1}[g_j(H(N, x, s)) \le 0] \,. \quad (1)$$

结构非法、求解不收敛或任一约束失败均记为不合格。每题有八个开发与八个保留工况；模型仅选择四个开发工况获取当前候选反馈，方案冻结后才评分全部十六个工况。$Q = 1$ 只表示有限合同内合格，不表示现场安全或完整连续运行包络已被覆盖。

源网络来自 SimBench、pandapower 和 WNTR 公开模型库 [7–9]。23 个候选网络中，16 个在有界搜索内取得可复算的可行参考，包括 13 个配电和 3 个供水网络；其余七项保留排除理由，未找到参考不等于不可行。设备加强上限依据参考需求校准，故这些任务代表筛选后的有限设计问题。六题在固定参考硬件下所有批准恒定档位均失败，而分时控制通过；九题记为设备与控制耦合设计，另保留一题易题锚点。这些标签不证明任意硬件都必须采用分时控制。

配电使用四个交流潮流快照，覆盖指定线路回路或变压器组中一个单元退出，不覆盖暂态稳定或完整 $N-1$ 安全性。供水保留原始水源水头、需求模式、储水初值与启停条件，不覆盖水质、瞬变或完整运维经济性。参考方案、精确保留组合及保留测量不提供给模型；源网络八个开发工况的基线行为对所有路线可见。

表 1. 两类合同的批准动作与合格判据。目录、阈值和运行条件在模型调用前固定；详细网络及工况见附录A、B。

领域	设计空间	全部工况须满足的约束
配电	负荷增长系数 1.30；所选线路加强为三回并联；变压器组采用统一并联单元数；共享四个六小时时段分接头日程。	母线电压 0.95–1.05 pu；线路及变压器负载率不超过 100%；指定单元退出时不失供且求解收敛。
供水	需求增长系数 1.25；批准管段管径加强；批准泵的四时段相对速度；指定水箱控制阈值偏移。	48 小时模拟，每 15 分钟检查：正需求节点压力 25–120 m、供水比例至少 99.9%、水箱位于原边界内、期末水位下降不超过 1 m。

2.2. 反馈与审查的权限

图1概括主流程。三种网关声明配置 `gpt-5.4`、`qwen3.8-max`、`kimi-k2.5` 在每网各重复两次，形成 $16 \times 3 \times 2 = 96$ 个初始方案 $x^{(0)}$。生产者先生成方案，再在未看到当前候选测量时选择四个不同开发工况；宿主执行这些测试，审查者给出判断、违反项、覆盖缺口和建议，原生产者修订一次。修订结构无效时保留初始方案；原方案非法时，沿用并不会修复其错误。

二乘二主对照只改变候选反馈可用性与审查者配置关系。无反馈路线屏蔽当前候选的证据，仍保留源网络基线；有反馈可能获得数值轨迹，也可能获得结构错误或求解失败信息。因此完整分母的效果不能全部解释为纯数值反馈作用。同家族审查使用生产者配置；跨家族在两次重复中依次使用另外两种配置。网关名称及请求设置不能认证真实后端权重，本文不将这种关系解释为架构因果效应。

审查屏蔽路线复用同家族有反馈路线的初始方案、选测与候选证据，将整个审查对象替换为屏蔽标记，再由原生产者修订。因此该对照检验完整审查输出的附加价值，同时移除判断、理由和建议，并非纯语言解释消融。每个起点共 11 次实际请求；四条主路线共享生产与选测调用。全部 1,056 次请求中两次失败，结果均保留；主对照不匹配 token、金额或内部推理计算。完整调用结构、设置和失败处理见附录C、F。

同起点 CPU 规则和有限搜索作为工程参照。规则按测量调整设备及控制，搜索依次评估八个候选、最多 32 条逻辑轨迹，只接受开发违反目标严格下降的候选。它们允许把非法初始方案重置为基础设计，预算和权限不同于模型路线，故不能据合格数作同资源算法排名；细节见附录C.1。另有每网一次的 CPU 从头设计，分母为 16。

3. 候选反馈有效，额外审查收益未建立

3.1. 完整分母与保留工况

图2汇总全部起点。初始方案合格 45/96；无反馈的同家族、跨家族路线分别为 46/96、44/96，有反馈时为 64/96、65/96。同家族反馈带来 20 个不合格转合格和 2 个反向变化，跨家族为 22 个与 1 个；配对净增量 $(G - L)/96$ 分别为 18.75、21.88 个百分点。

收益主要来自配电：同家族由 31/78 增至 48/78，跨家族由 27/78 增至 49/78。供水初始已合格 15/18，有反馈两条路线均为 16/18，无反馈跨家族却为 17/18，因此不能表述为两域一致受益。所有 96 个起点均保留，其中 18 个初始方案结构非法，主效果包含结构修复与物理约束改善。所有请求完成、初始可执行且四条数值轨迹完整的事后子集为 77 个起点；同家族由 44 增至 60，跨家族由 41 增至 60。该子集表明收益不只发生在非法起点上，但不替代完整分母，也未分离反馈各成分。

表 2. 不同工况组全部通过的方案数，各列分母均为 96。开发与保留各八个工况，完整合同为其交集。更细的所选／未选开发结果见附录13。

路线	开发	保留	完整合同
初始方案	46	48	45
无反馈／同家族	46	51	46
无反馈／跨家族	45	46	44
有反馈／同家族	65	68	64
有反馈／跨家族	66	70	65
审查屏蔽	66	69	64

冻结评分的事后分组结果见表2。保留八工况的同家族合格数由 51 增至 68（改善 20、损失 3），跨家族由 46 增至 70（改善 24、损失 0）。未选开发四工况也分别由 49 增至 70、48 增至 71。这表明本批反馈收益不限于模型选择的四个测试，但仍是同一组网络上的有限组合验证，而不是新网络泛化。

排除六个开发烟测起点后，分母为 90，完整合同同家族由 43 增至 60，跨家族由 41 增至 61。每次删除一个网络的六个起点，反馈净增量分别落在 13–18 和 16–22 个之间，因此不由某一个网络单独决定。这些是事后敏感性范围，不是置信区间。原入口曾在烟测后、保留评分和扩大调用前修订；排除烟测不能把研究恢复为未变更的预注册。详细分层与删样记录见附录F、E。

3.2. 额外审查与工程参照

有反馈跨家族相对同家族只有 5 个改善、4 个损失、87 个持平，净差 1.04 个百分点。完整同家族审查与屏蔽审查均合格 64/96，各有四个起点更好。总数相同不表示逐例等价；本研究既未建立稳定额外收益，也未以等效性或非劣效检验证明可以普遍删除审查。按有向配置细分时，审查方向与重复编号绑定，不能独立识别审查者身份的作用。

同起点 CPU 规则合格 63/96，有限搜索为 73/96；从头规则、搜索分别为 12/16、13/16。有限搜索的数量更高，但其额外候选和重置权限阻止了同资源优越性解

固定合同与起点	候选执行验证	审查与一次修订	冻结后统一评分
16 网、96 个初始方案；批准设备及控制动作。	选 4/8 开发工况；保存结构、求解及数值证据。	有／无候选反馈 × 同／跨家族审查；原生产者修订。	8 开发 + 8 保留工况；保留结果不回流模型。

图 1. 同起点评估流程，由左至右执行。主对照共享初始方案、选测和修订机会；反馈权限同时作用于审查与修订。另设完整审查屏蔽及 CPU 工程参照，路线并非独立样本。

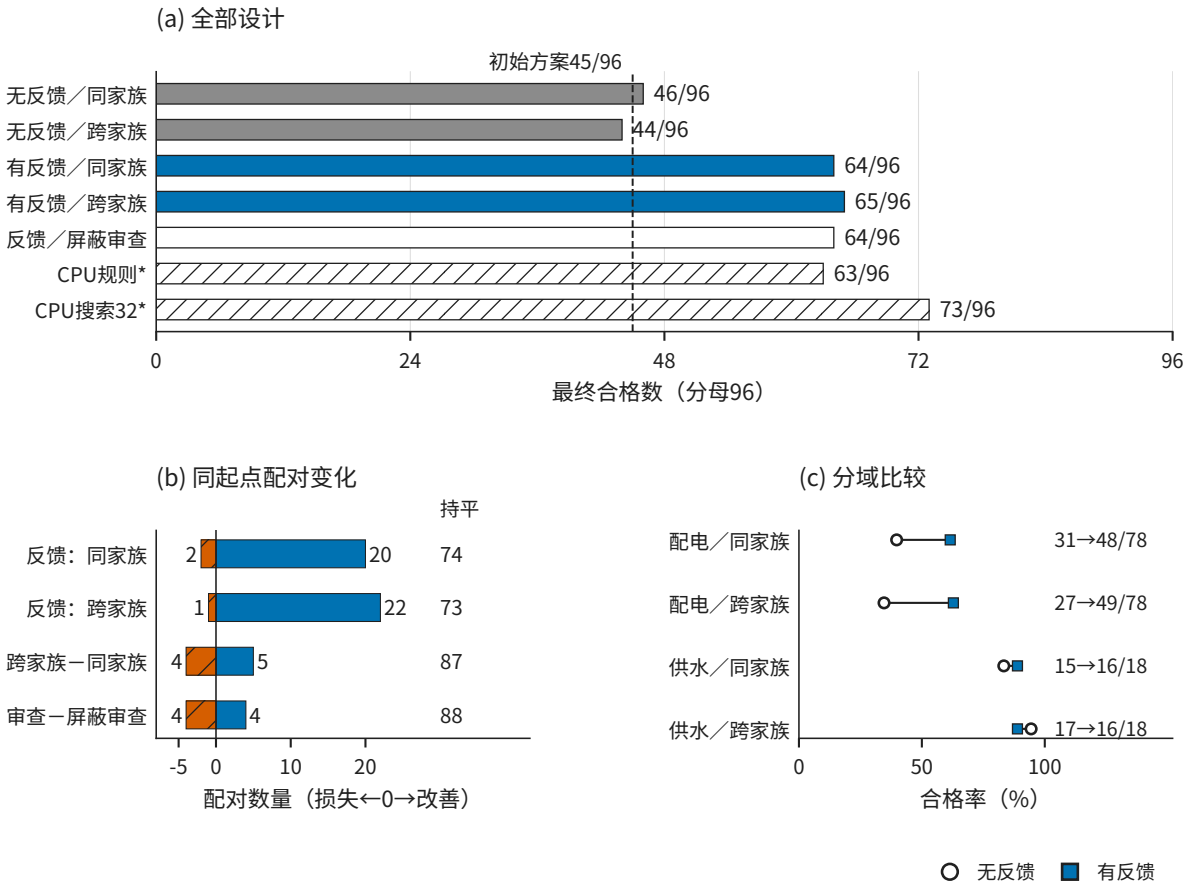


图 2. 完整合同结果与配对变化。各路线分母 96；初始合格数为 45。星号 CPU 参照的预算及结构重置权限不同。(b) 改善、损失与持平逐例计数。(c) 配电分母 78，供水 18；空心圆、实心方形分别表示无反馈、有反馈。

释。反过来，这些结果也没有证明复杂审查流程具有采用上的必要性。本文支持的是候选执行反馈在当前条件中的效用，而不是整个多角色流程相对简单工程程序的优势。

4. 执行语义与修改退步

4.1. 动作忠实性会改变标签

仿真宿主必须核查实际动作，而不能以求解器正常返回作为正确性证明。旧供水接口的原生开泵命令可能把预设速度恢复为 1；直接附加速度模式又可能重新打开原本关闭的泵。修正宿主把速度日程和原始启停条件联合编译，核查实际速度、可用窗口及阈值偏移。

对旧批次 24 条供水最终路线的零模型调用语义复评中，六条标签改变：四条由失败转通过、两条反向变化，全部发生于 ky4。该结果说明动作编译偏差足以改变工程评估，而不是只影响日志。旧模型没有收到修正测量，因此这次复评不能用于重新排列旧反馈路线的效能，也不能估计此类错误在其他宿主中的发生率；完整结果见附录D.1。

4.2. 局部回退区分有效修改与退步

在全部方案冻结后，依据改善、退步及开发通过但保留失败类别，按字典顺序选择可执行路线做事后回退。每

次仅恢复一个字段至初始值，其他最终参数与十六个工况不变。表3保留两个直接说明工程作用的案例；四例全量记录及测量见附录F的图4。

表 3. 局部动作回退的失败工况数，每个方案共 16 个工况。回退只支持指定硬件和其余字段固定时的作用。

案例／回退字段	初始	最终	回退后
低压乡村 2 ／分接头日程	16	0	16
中压城区／线路选择	0	5	0

低压乡村 2 的硬件保持不变，分接头日程由 $[-1,-2,1,-2]$ 改为 $[0,0,1,0]$ 后全部通过；恢复原日程使十六个工况再次失败。初始正常日第二、四个快照最高电压约为 1.0619、1.0642 pu，超过 1.05 pu 上限。中压城区则从全部通过退步为五个工况失败，恢复初始线路选择后重新全部通过。这两例分别定位了控制收益与设备修改退步，而不只是展示最终参数差异。

另外，Net1 的失败数从 3 降至 0；恢复泵速仍通过，恢复水箱阈值才重新失败，不能把收益全部归因于泵速。中压乡村最终仍有两个失败，恢复线路无效，恢复分接头后全部通过。这些回退提供指定字段的局部作用证据，不反映模型内部推理，也不证明总体机制或审查解释必要性。它们提示评估应分别保留声明参数、实际动作、测量与标签，以便发现不忠实执行和修改退步。

5. 材料与最小复用示例

5.1. 三种可复用对象

材料按用途提供三个层次。第一，冻结任务合同规定批准资产、动作目录、工况和判据，可用于审查一个候选方案是否回答了同一道工程题。第二，`analysis/compact_scores.json` 和 `analysis/analyze_scores.py` 保存逐路线评分与可重跑统计，使读者无需模型调用或物理仿真即可核对分母、配对、条件子集与敏感性结果。第三，最小 CPU 示例包含两域的源网络、合同、冻结初始与最终方案以及原评分实现，允许从网络重新计算结果，而不只读取已有标签。

完整原批次请求日志及实验环境仍保留在研究归档。轻量协议补件本身不是全量实验发行包；新增示例兑现的是两个指定网络的执行与方案评分入口，不是原 96 个起点的模型生成和审查重跑，也未自动接入新的模型服务。

5.2. 从源网络重放四份冻结方案

示例位于研究仓库的 `examples/engineering-replay/`，选择 `kerber_overhead` 与 `Net1`。两者均取原批次 `gpt-5.4`、重复 0、同家族有反馈路线的初始及最终方案，共四份方案，每份执行八个开发与八个保留工况。这里的 64 是工况评估次数，而不是 64 个新工程任务；配电每工况含四个潮流快照，供水每工况为 48 小时水力模拟。

在已具备记录依赖的环境中，进入示例目录运行 `pythonrun_demo.py` 即可开始重放，不需要 API 凭据、模型服务、GPU 或原研究目录。程序先核对源网络、合同和原评分实现的散列，再执行评分。表4给出对应的预期结果；供水初始方案不合格是应被重现的结果，不是复现失败。配电初始与最终参数相同，因此该案例检验保留方案的重放，不作为新增改进案例。

表 4. 最小示例的既有方案 CPU 重放。每份方案 16 个工况；标签与逐项判据均匹配冻结记录，未新增模型请求。

网络	初始 Q	最终 Q
Kerber 架空	1	1
Net1	0	1

首次运行的四份评分均匹配冻结记录；将示例打包后解压到另一目录、用同一解释器再次运行，64 个工况仍匹配，两次实际评分对象也逐值相等。另新建不继承系统包的虚拟环境，按记录依赖安装并检查无破损后，64 个工况再次匹配，实际评分与首次重放逐值相同。比较要求结构错误、求解失败、判据和标签精确一致，数值测量采用绝对 10^{-6}、相对 10^{-8} 的重放容差。这是结果比较容差，不改变电压、压力等工程合格阈值。运行记录、完整依赖版本清单和验证报告随示例提供。

5.3. 评估另一份方案，而非重新定义合同

示例也提供自定义方案入口：将符合任务结构的方案保存为 `candidate.json`，对 `run_demo.py` 指定 `--caseNet1`、`--designcandidate.json` 和输出路径，即可在同一冻结合同下运行十六个工况。该路径已执行验证；它输出候选的逐项测量、约束检查和最终标签，不要求新方案复现旧方案的数值。这样，人工或外部模型提交的参数可以进入相同判定器，而不必改写仿真逻辑。此入口的通过只表明调用和评分路径可用，不构成新模型性能实验。

两个默认案例已通过原环境、异目录解压和新隔离依赖环境重放；后者仍使用同一 Windows 机器与基础 Python。异机、跨操作系统兼容性及独立物理求解器尚未验证。新增网络还需重新确定资产权限、工况、物理约束、动作映射与可行参考；不能把替换输入文件等同于得到一个已验证的新任务。公开保留工况用于核查，后续模型实验仍需隔离其提示输入，并重新冻结生成与审查协议。

研究源码与材料入口为 https://github.com/Sumimi24/opentrust-research，说明页面为 https://sumimi24.github.io/opentrust-research/。当前复用价值因而可以具体表述为：检查同一合同、重算已有统计、重放两域方案，以及评分符合既有合同的另一份参数设计；更广网络的效用和整个流程的外部复现仍待验证。

6. 讨论与结论

现有结果支持三个层次的结论。第一，在筛选后的有限合同中，候选执行反馈改善了完整合同及保留工况的合格数，且主要来自配电。第二，更换审查配置或提供完整审查输出的稳定附加收益尚未建立，不能用系统角色数量替代效用验证。第三，动作语义和局部退步可以改变标签，必须与方案质量共同审计。这些结论属于工程评估的实证增量，不构成新的生成算法或普遍方法优势。

适用范围受到可行参考筛选、公开网络相关性及供水样本偏少的限制。96 个起点与 672 条路线不能当作独立网络样本；声明模型身份未认证，token、费用与内部计算未匹配。审查数值引用尚未可靠逐项核验，故不报告解释失实率。同软件同判据的冻结方案复算只验证重现性，不能替代独立物理模型或现场测量；局部回退也只是事后选例。

后续工作应对准尚未回答的决定：在同一初始方案上分离结构诊断、数值反馈与审查建议，检验何时需要审查；在独立来源网络和困难供水任务上预先冻结协议，检验收益迁移；用预算与权限匹配的工程优化对照评估采用成本。当前可以复用的是明确的合同、失败处理和评分证据。它们使后续方案能够在相同条件下被检查，但未来可扩展性本身不计作已完成的性能贡献。

参考文献

[1] N. Do, A. Marchi, and P. Hayde. Accelerating water distribution systems planning and design with generative artificial intelligence models. *Cambridge Prisms: Water*, 4:e2, 1–7, 2026. 1

[2] Yinon Goldshtein, Gal Perelman, Assaf Schuster, and Avi Ostfeld. Large language models for water distribution systems modeling and decision-making. *arXiv preprint arXiv:2503.16191v2*, 2026. 1

[3] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan, and Weizhu Chen. CRITIC: Large language models can self-correct with tool-interactive critiquing. In *International Conference on Learning Representations*, 2024. 1

[4] Yunkai Hu, Tianqiao Zhao, and Meng Yue. From natural language to solver-ready power system optimization: An LLM-assisted, validation-in-the-loop framework. *arXiv preprint arXiv:2508.08147*, 2025. 1

[5] Zicheng Lin, Zhibin Gou, Tian Liang, Ruilin Luo, Haowei Liu, and Yujiu Yang. CriticBench: Benchmarking LLMs for critique-correct reasoning. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 1552–1587, 2024. 1

[6] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-Refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, 2023. 1

[7] pandapower. Power system test cases and network documentation. `https://pandapower.readthedocs.io/en/latest/networks.html`. Accessed 2026-10-15. 1, 6

[8] SimBench. Benchmark network documentation. `https://simbench.readthedocs.io/en/stable/networks.html`. Accessed 2026-10-15.

[9] U.S. Environmental Protection Agency. WNTR network library documentation. `https://usepa.github.io/WNTR/libraries.html`. Accessed 2026-10-15. 1, 6

[10] Jiaqi Wen, Pingbo Tang, Shaolei Ren, and Jianyi Yang. WaterAdmin: Orchestrating community water distribution optimization via AI agents. *arXiv preprint arXiv:2604.10343*, 2026. 1

[11] H. Wu, X. Wang, and Z. Fan. Knowledge boundary probing and demand-guided intervention for LLM-based power system code generation. *arXiv preprint arXiv:2605.31478v2*, 2026. 1